Plan your trip with KAYAK

Construire un pipeline pour recommander automatiquement les meilleures destinations de vacances en France.

70 %

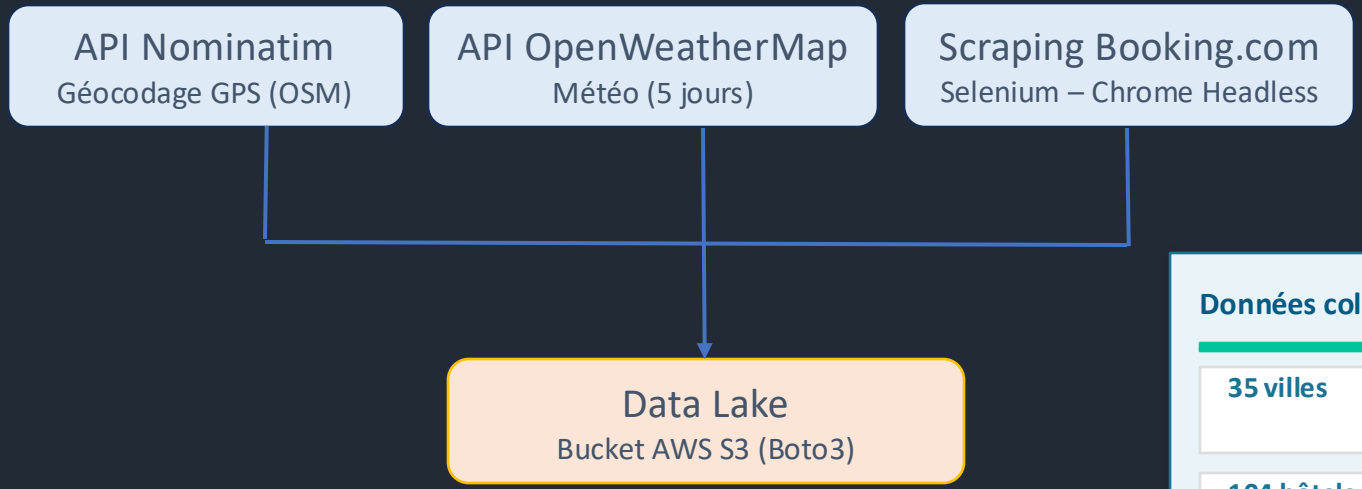
des utilisateurs Kayak

souhaitent plus d'informations sur leur destination avant de réserver.
Kayak n'a pas encore d'outil de recommandation basé sur des données réelles.

- Python
- Selenium
- APIs
- Pandas
- AWS S3, Redshift
- SQLAlchemy

Samer MECHHOUD

Collecte de données



Données collectées

35 villes	géocodées + Météo
104 hôtels	scrapés (Selenium)
1 CSV dans S3	104 lignes x 22 colonnes

Collecte : Nominatim · OpenWeatherMap · Selenium → Data Lake

Pipeline ETL



- Le score météo est sur 100 points, établi selon la fromule:

Score_meteo = 4 * note_pluie + 3 * note_soleil + 2 * température + 1 * Vent

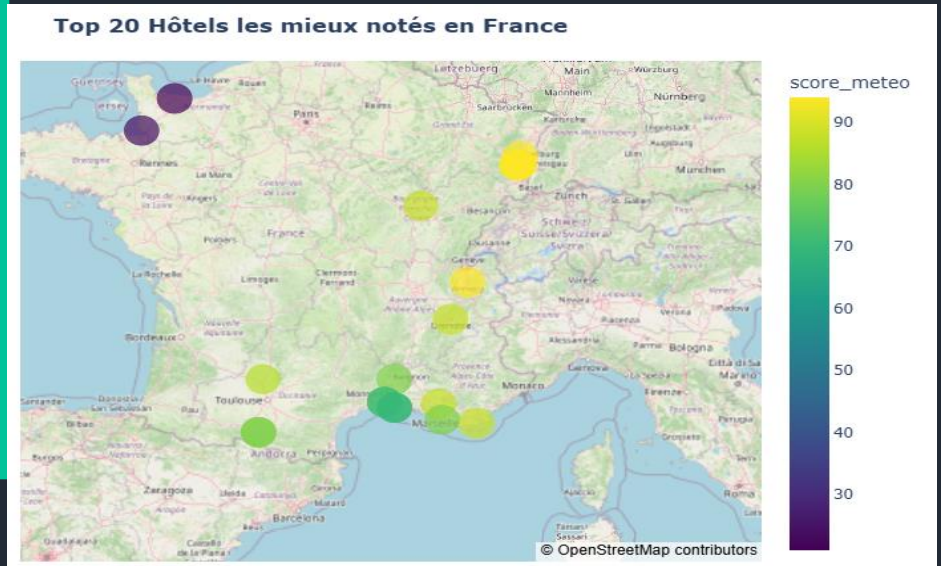
Résultats - Visualisations interactives Plotly

- Avec SQLAlchemy, on requête la database Redshift pour récupérer le top 5 des destinations et le top 20 des hôtels.
- On visualise les résultats via Plotly (map plot).

Top 5 Destinations



Top 20 Hôtels



Points techniques, Limites & Conclusion

Ce que ce projet démontre

- Collecte multi-sources : API REST + Scraping Selenium
- Pipeline ETL structuré avec scoring métier
- Conformité RGPD : aucune donnée personnelle · clés protégées (.env)
- Architecture Data Lake / Data Warehouse séparée

Limites identifiées

- Booking bloque à 3 hôtels/ville → rotation de proxies
- Temps de scraping large → attente intélligente, WebDriverWait

Perspectives

- Automatiser le pipeline
- Enrichir le dataset avec les prix de trains, avions, ...
- Exposer le pipeline via une API FastAPI

Merci de votre attention !

Des questions?