W A L M A R T

Prédiction des ventes hebdomadaires

Projet Machine Learning supervisé - Régression linéaire et régularisée

Stack technique : Python | pandas | scikit-learn

Samer MECHHOUD

01 - Contexte et objectifs

Contexte

Walmart Inc. est le premier distributeur mondial, fondé en 1962 par Sam Walton.

Le service marketing souhaite un modèle capable d'estimer les ventes hebdomadaires de ses magasins.

Un tel modèle permettrait de mieux comprendre l'influence des indicateurs économiques et d'optimiser les campagnes marketing.

Objectifs du projet

Partie 1	EDA et prétraitement des données
Partie 2	Modèle de régression linéaire (baseline)
Partie 3	Régularisation Ridge et Lasso - Optimisation de l'hyperparamètre alpha via GridSearchCV

02 - Description du jeu de données

150
observations initiales

8
variables d'origine

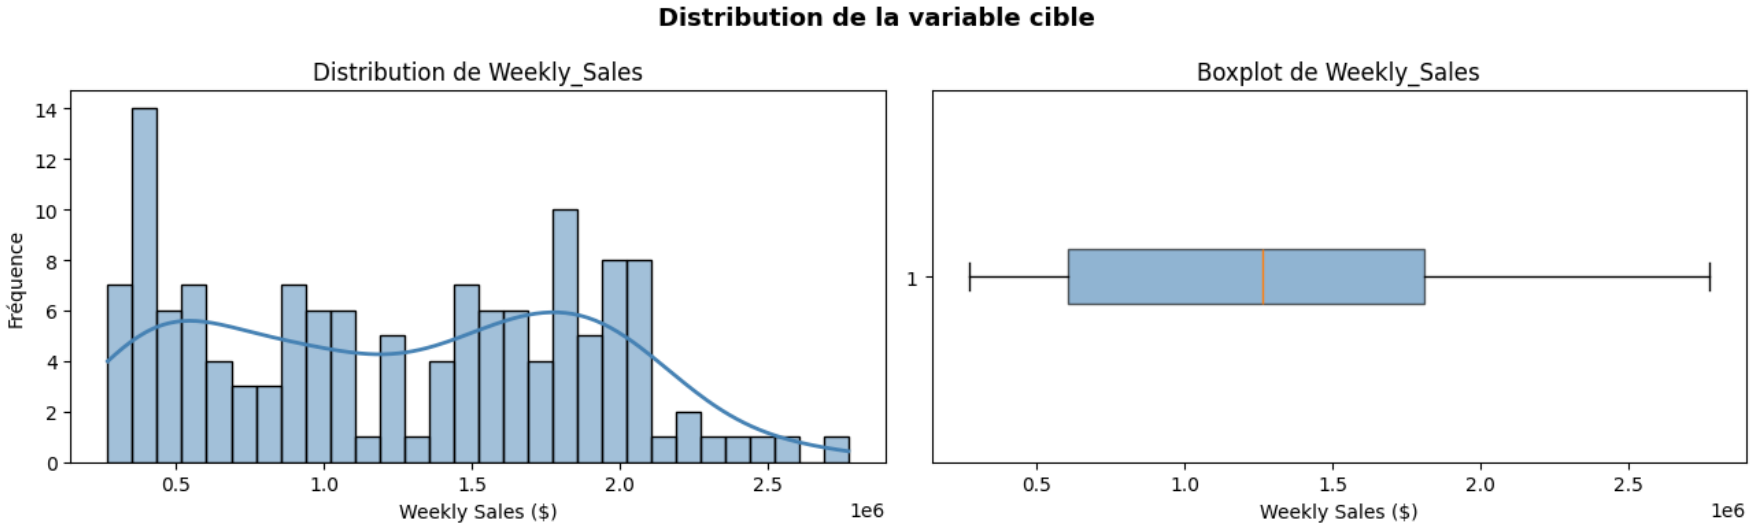
109
observations après nettoyage

36
features après preprocessing

Variables du dataset

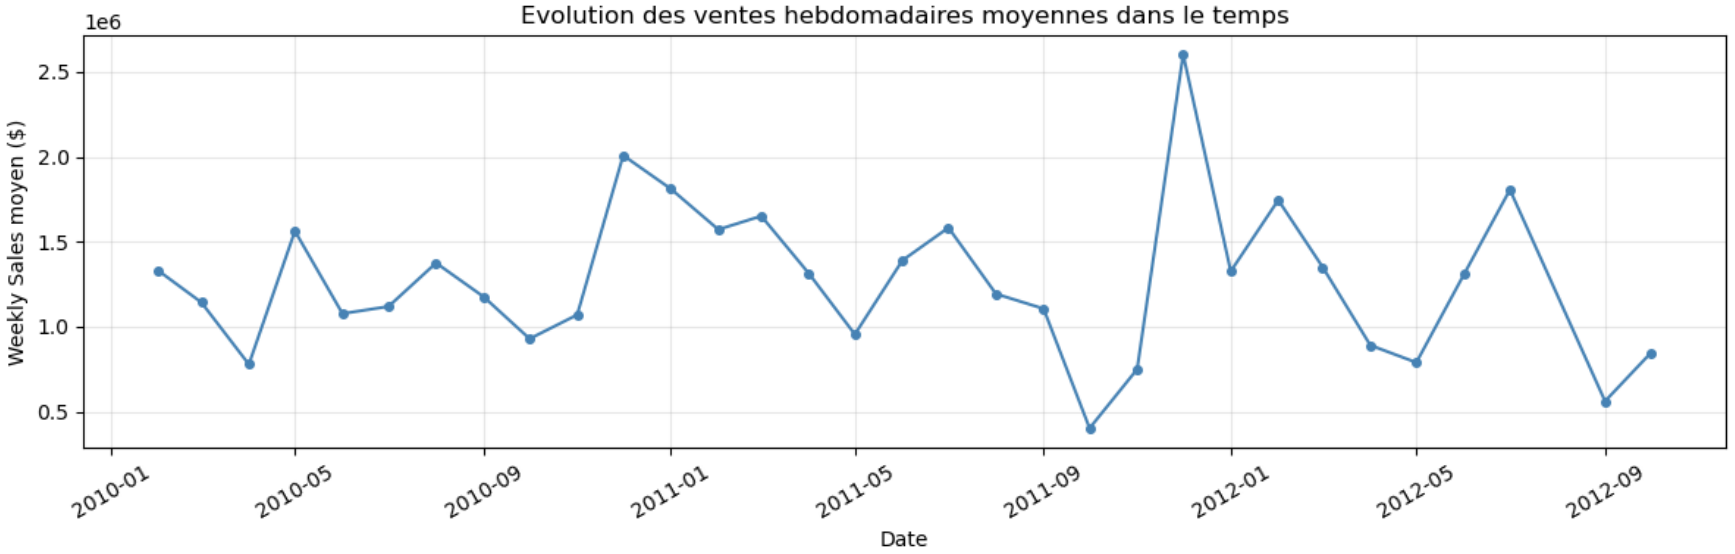
Variable	Type	Description	Rôle
Weekly_Sales	Numérique	Ventes hebdomadaires ($)	Target (y)
Store	Catégorielle	Identifiant du magasin (19 magasins)	Feature X
Holiday_Flag	Catégorielle	Présence d'un jour férié (0 ou 1)	Feature X
Temperature	Numérique	Température régionale (degrés F)	Feature X
Fuel_Price	Numérique	Prix du carburant ($)	Feature X
CPI	Numérique	Indice des prix à la consommation	Feature X
Unemployment	Numérique	Taux de chômage régional (%)	Feature X
Date	Date	Semaine - décomposée en Year/Month/Day (DayOfWeek écartée - variance nulle)	Feature X (transformée)

03 - EDA - Distribution des ventes



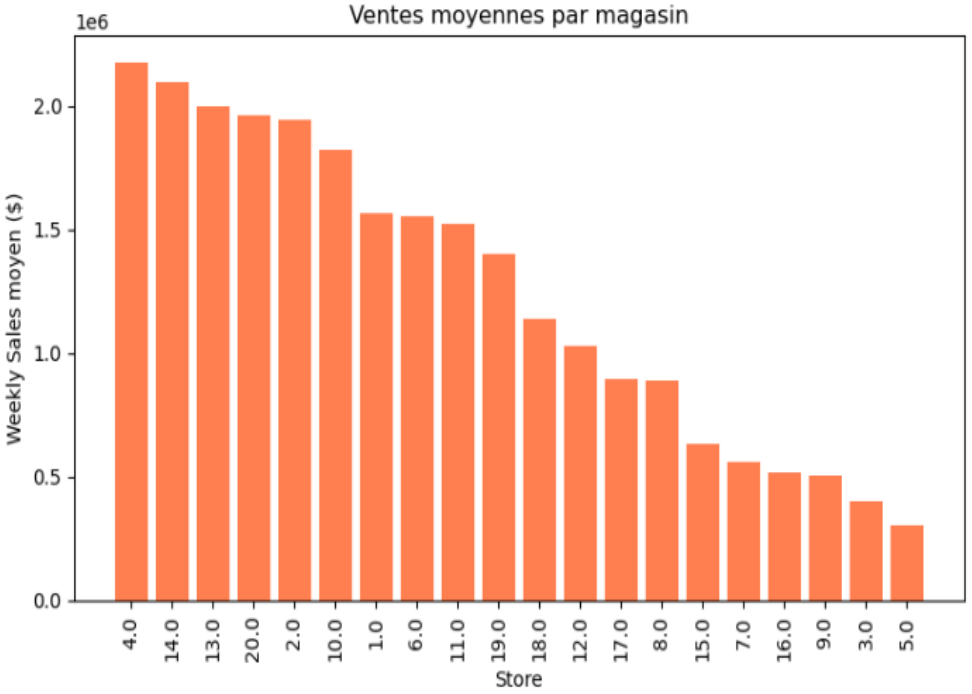
Distribution bimodale des ventes (270k$ à 2,8M$) : deux groupes de magasins aux profils distincts.

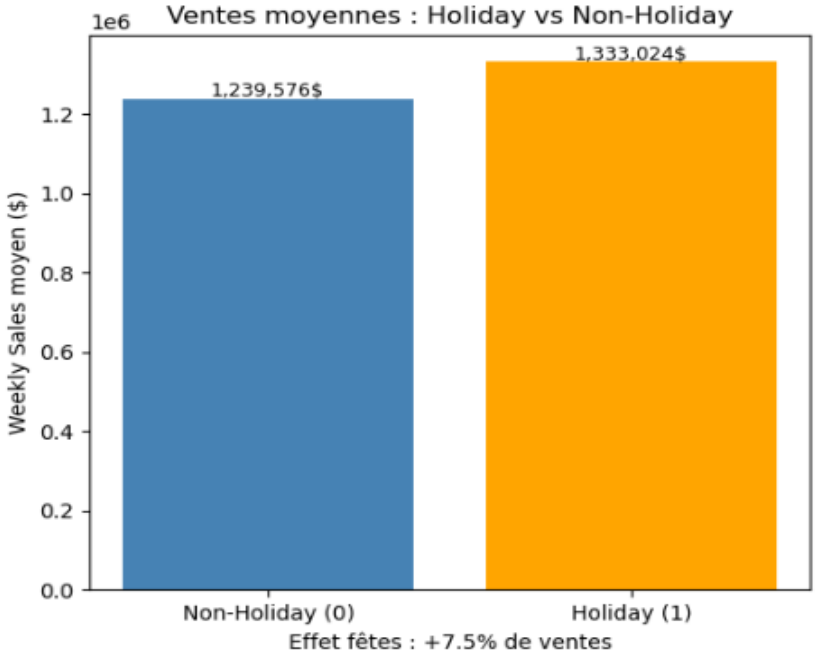
Analyse exploratoire – Evolution des ventes



Possibilté de pésence de tendance saisonnière --> nécessité d'extraction des features temporelles (Year, Month, Day) depuis la colonne Date.

Analyse exploratoire – Effet magasins et jours fériés

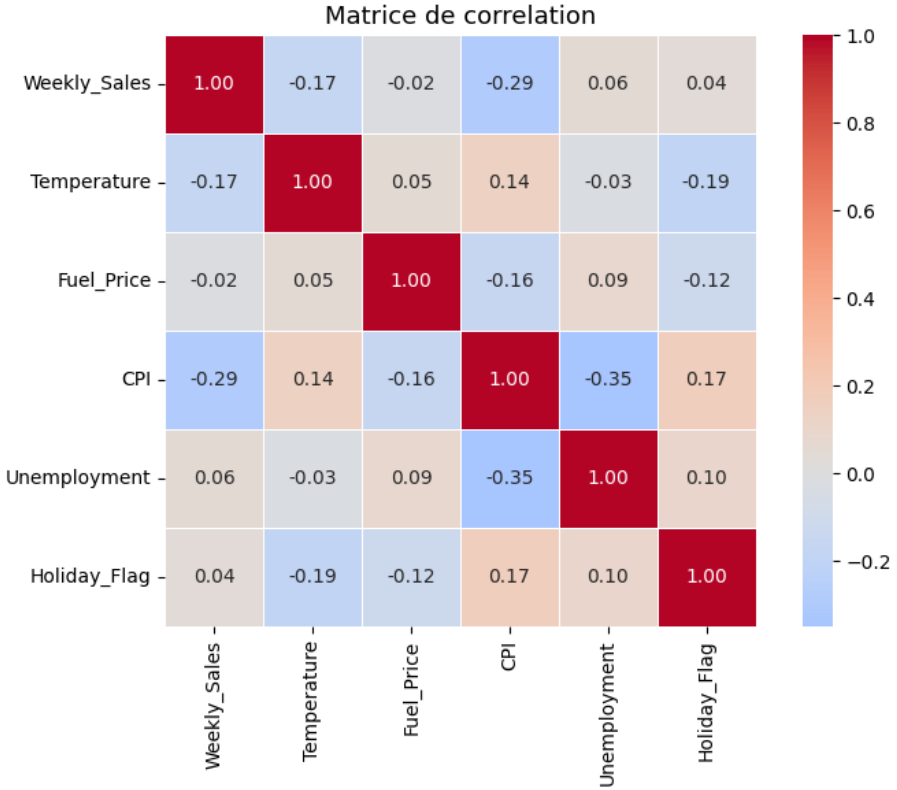




Hétérogénéité inter-magasins réelle

Les semaines de fêtes génèrent en moyenne +7,5 % de ventes.

Analyse exploratoire - Matrice de corrélation



Aucune variable seule n'est fortement corrélée à la cible: c'est pour cela qu'il faut les combiner.

04 - Prétraitement des données

Prétraitement avec pandas

Étape 1 Suppression des 14 lignes ou Weekly_Sales est manquant
(aucune imputation sur la variable cible)

Étape 2 Décomposition de Date en 3 features : Year, Month, Day

Étape 3 Analyse des outliers hors [Q1–1.5IQR, Q3+1.5IQR] sur Temperature, Fuel_Price, CPI, Unemployment

Prétraitement avec scikit-learn

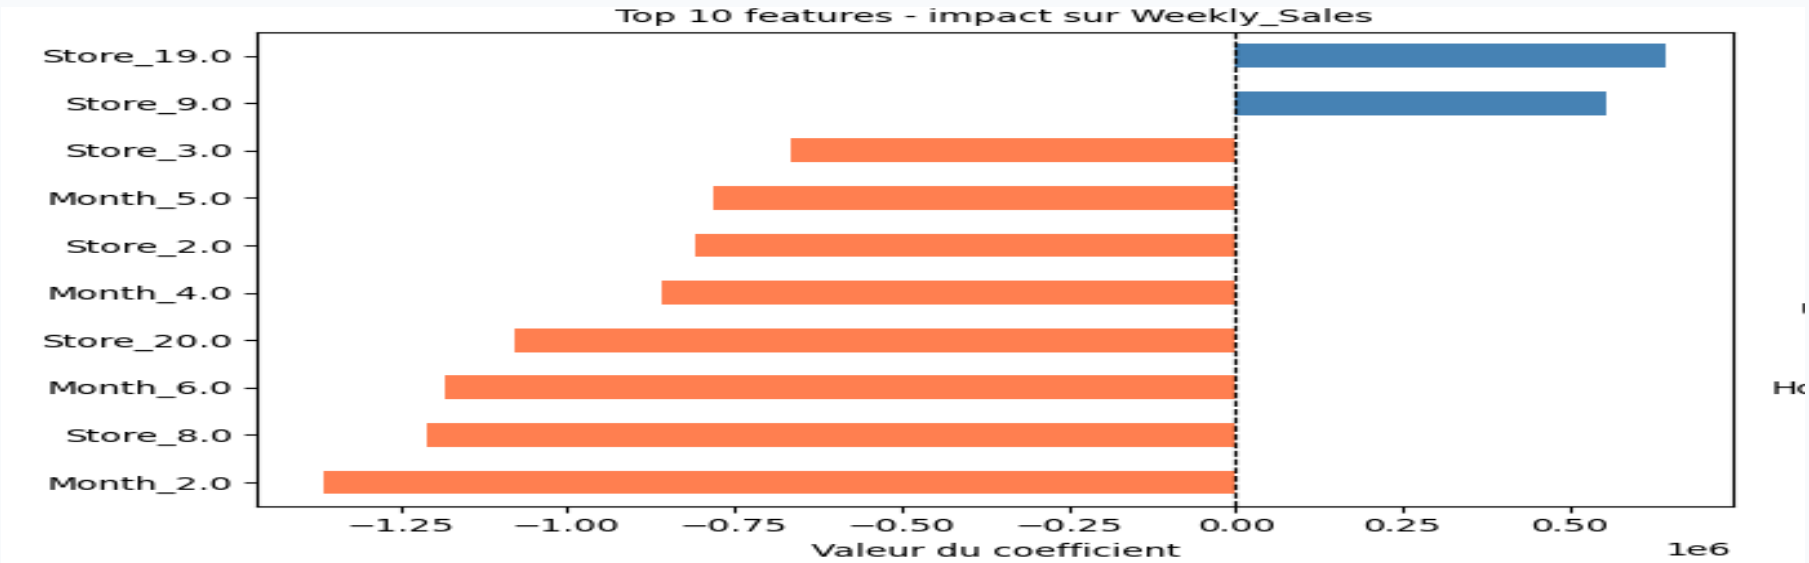
OneHotEncoder
Store
Holiday_Flag
Month

SimpleImputer(median) + StandardScaler
Temperature, Fuel_Price, CPI, Unemployment
Year

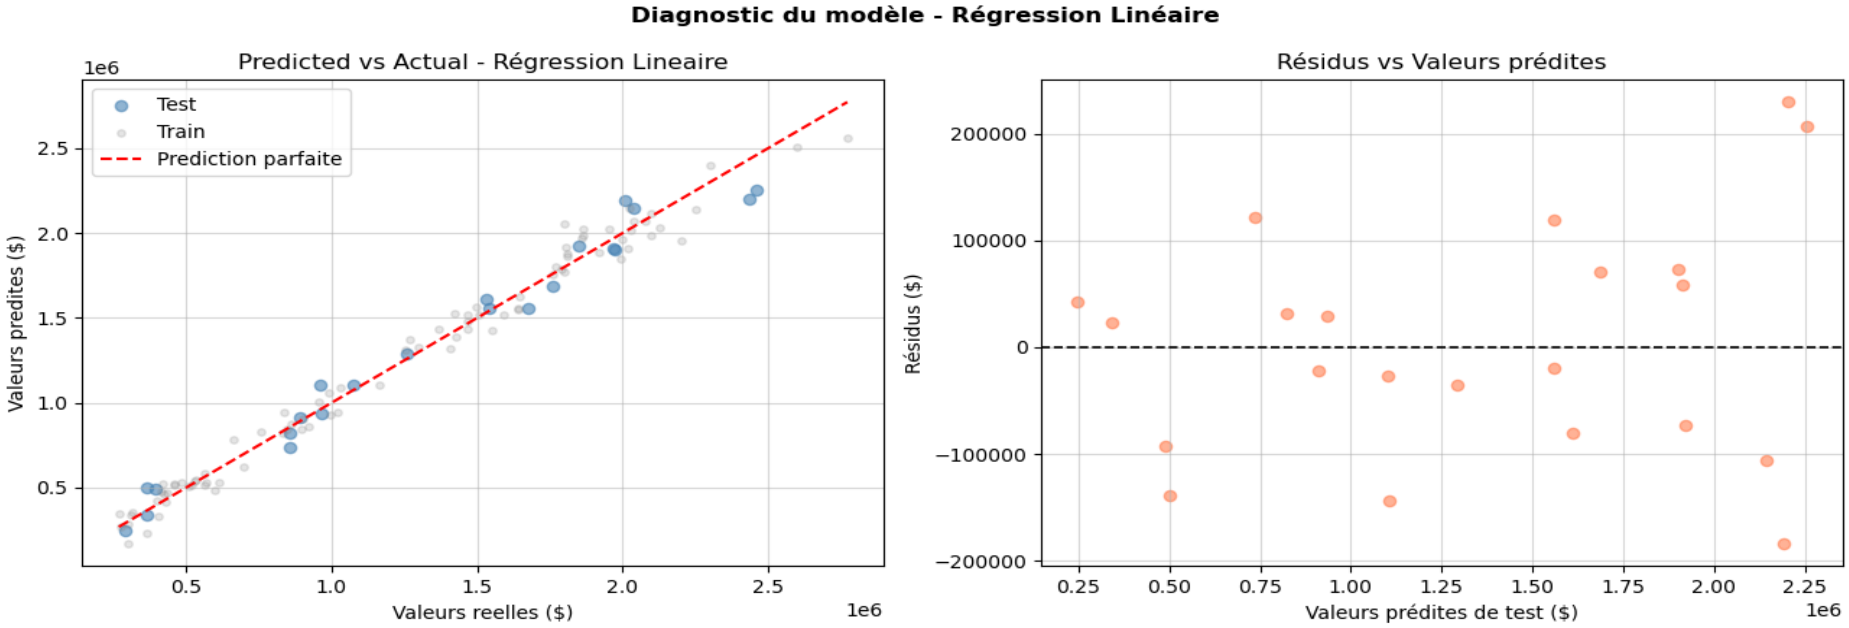
05 - Modélisation - Régression linéaire (Baseline)

0.9841	0.9742	87 636 $	106 779 $
R^2 Train	R^2 Test	MAE Test	RMSE Test

Écart Train-Test : 0.001 - Pas de surapprentissage (overfitting) détecté.



Diagnostic du modèle - Régression linéaire



Les prédictions se regroupent autour de la droite parfaite (y=x), confirmant la performance globale du modèle.

les résidus sont distribués aléatoirement autour de 0 --> absence d'overfitting, pas d'effet entonnoir

06 - Régularisation - Ridge et Lasso + GridSearchCV(5)

La régularisation pénalise les grands coefficients.
L'hyperparamètre alpha contrôle la force de la pénalité : plus alpha est grand, plus les coéfficients sont réduits.

Ridge (L2) - Meilleur alpha = 0.01

Principe :
Pénalise la somme des carrés des coefficients (L2).
Ridge a réduit tous les coefficients sans en annuler.

GridSearchCV (cv=5) :
Meilleur alpha = 0.01.

Résultats :
R^2 Train : 0.9841 | R^2 Test : 0.9757
MAE : 83 709 $ | RMSE : 103 738 $
Les erreurs ont baissé par rapport au modèle de base.

Lasso (L1) - Meilleur alpha = 1000

Principe :
Pénalise la somme des valeurs absolues (L1).
Lasso a annulé 8 features dont Holiday_Flag_1.0, CPI, Unemployment.

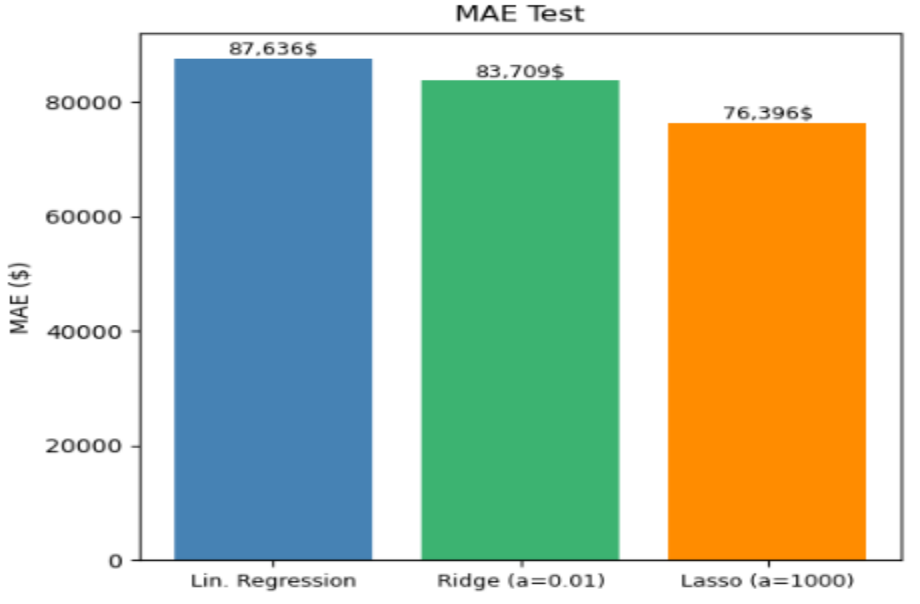
GridSearchCV (cv=5) :
Meilleur alpha = 1000.

Résultats :
R^2 Train : 0.9818 | R^2 Test : 0.9768
MAE : 76 396 $ | RMSE : 101 263 $
Les erreurs ont encore baissé.

07 - Résultats et comparaison des modèles

Tableau de performance comparatif

Modèle	R^2 Train	R^2 Test	MAE Test	RMSE Test	Ecart Train-Test
Régression Linéaire	0.9841	0.9742	87 636 $	106 779 $	0.0099
Ridge (alpha = 0.01)	0.9841	0.9757	83 709 $	103 738 $	0.0084
Lasso (alpha = 1000)	0.9818	0.7968	**76 369 $**	**101 263 $**	**0.0050**



Ridge réduit l'erreur MAE de 4.6%.

Lasso la réduit de 12.6%.

08 - Conclusions et recommandations

Modèle recommandé : Lasso (alpha = 1000) - MAE et RMSE les plus faibles, sélection automatique de variables, modèle moins complexe.

Variables les plus importantes

Store

Facteur dominant - hétérogénéité forte entre magasins

Month/Year

Facteur dominant - Tendances saisonnières des ventes

Unemployment/CPI

Absorbées par Store

Holiday_Flag

Absorbée par Month/Year

Recommendations pour le service marketing

- Concentrer les budgets promotionnels sur les semaines de fêtes. Planifier les campagnes en avance.
- Intensifier les promotions dans les bassins d'emploi fragilisés. Adapter la stratégie par zone géographique.
- Renforcer les offres prix lors des phases d'inflation. Adapter le positionnement sur les produits essentiels.

Merci de votre attention !

Des questions?