Défi du Taux de Conversion

Prédiction des abonnements à la newsletter Data Science Weekly

Samer MECHHOUD

01 Contexte & Données

Contexte du projet

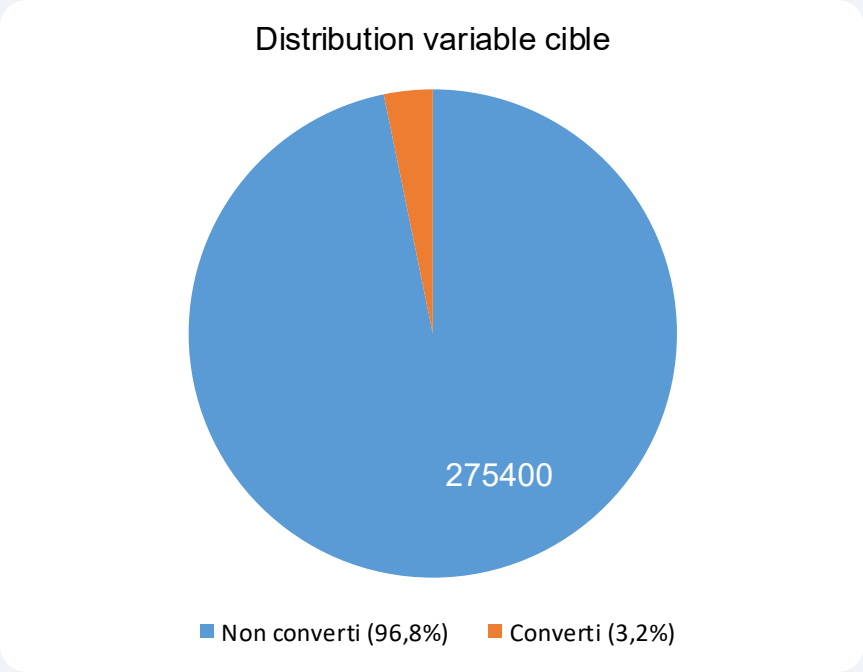
www.datascienceweekly.org
Newsletter hebdomadaire sur la data science rédigée par des experts indépendants.

Objectif : Prédire si un visiteur va s'abonner à partir de son comportement de navigation.

Variables du jeu de données

country *Catégorielle*	Pays (China, Germany, UK, US)
age *Numérique*	Âge du visiteur
new_user *Binaire*	1=nouveau, 0=existant
source *Catégorielle*	Ads / Seo / Direct
total_pages_visited *Numérique*	Pages vues en session
converted ★ *CIBLE*	1=abonné, 0=non abonné

02 Analyse Exploratoire — Déséquilibre & Anomalie



284 580	3,2 %	31 620
Visiteurs (train)	Taux de conversion	Visiteurs (test)

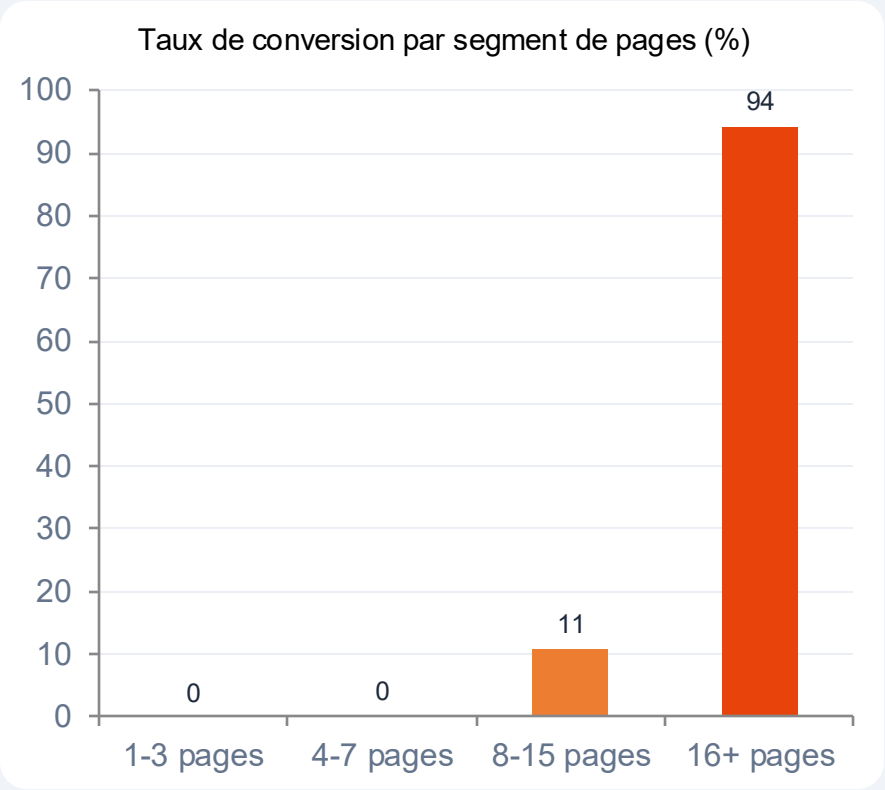
Anomalie détectée : âge = 123 ans

2 lignes avec un âge aberrant (111 et 123 ans) — clairement une erreur de saisie. Ces lignes ont été supprimées pour ne pas biaiser le modèle.

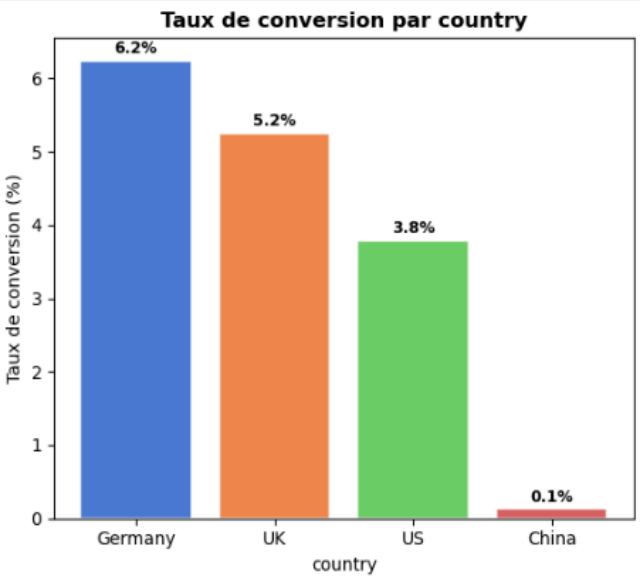
Il y a un fort déséquilibre entre les classes (que 3,2% de 1).

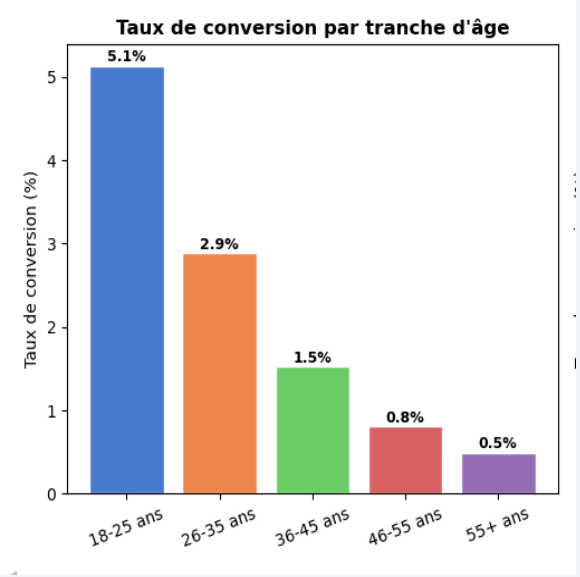
02 Analyse Exploratoire — Corrélations & Pages visitées

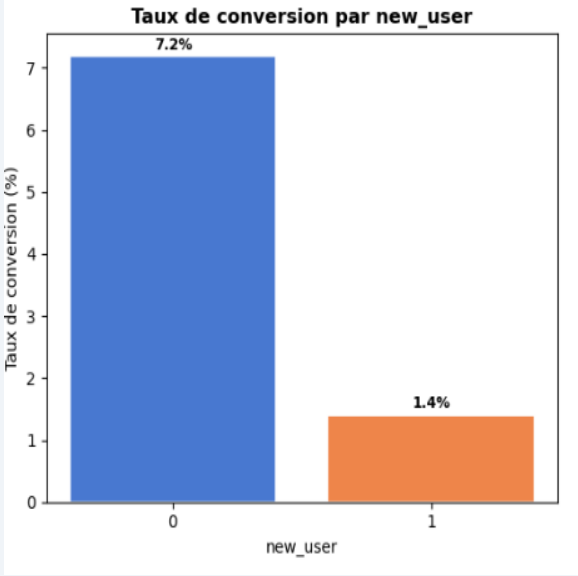
Corrélation avec converted	
total_pages_visited	+0,53
age	-0,09
new_user	-0,15



02 Analyse Exploratoire — Variables catégorielles







Chine : 0,1%

Probablement des contraintes réglementaires ou techniques .

Utilisateurs existants 5x plus

new_user=0 → 7,2% vs new_user=1 → 1,4% : ils connaissent déjà le site.

Les jeunes convertissent plus (5,1%)

03 Modélisation — 3 modèles comparés

Régression Logistique

BASELINE

- OneHotEncoder
- StandardScaler
- class_weight=None

F1	Precision/Recall
76,04%	85% / 69%

Modèle de référence.
Score F1 assez bon. Utiliser le class_weight='balance' réduira les performance.
Pas d'overfitting.

Random Forest + GridSerachCV(=5)

AMÉLIORÉ

- n_estimators=100
- max_depth=10
- min_samples_leaf=20
- class_weight={0: 1, 1: 2}

F1	Precision/Recall
76,13%	78% / 74%

Gestion native des non-linéarités.
Le F1 score est mieus réparti entre Precision et Recall.
Pas d'overfitting.

XGBoost + GridSearchCV(=5)

RETENU

- n_estimators=200
- learning_rate=0,01
- max_depth=7
- subsample=0,8
- Scale_pos_weight=2

F1	Precision/Recall
76,50%	81% / 73%

Construction séquentielle, corrige les erreurs itérativement.
F1 légèrement amélioré.
Pas d'overfitting.

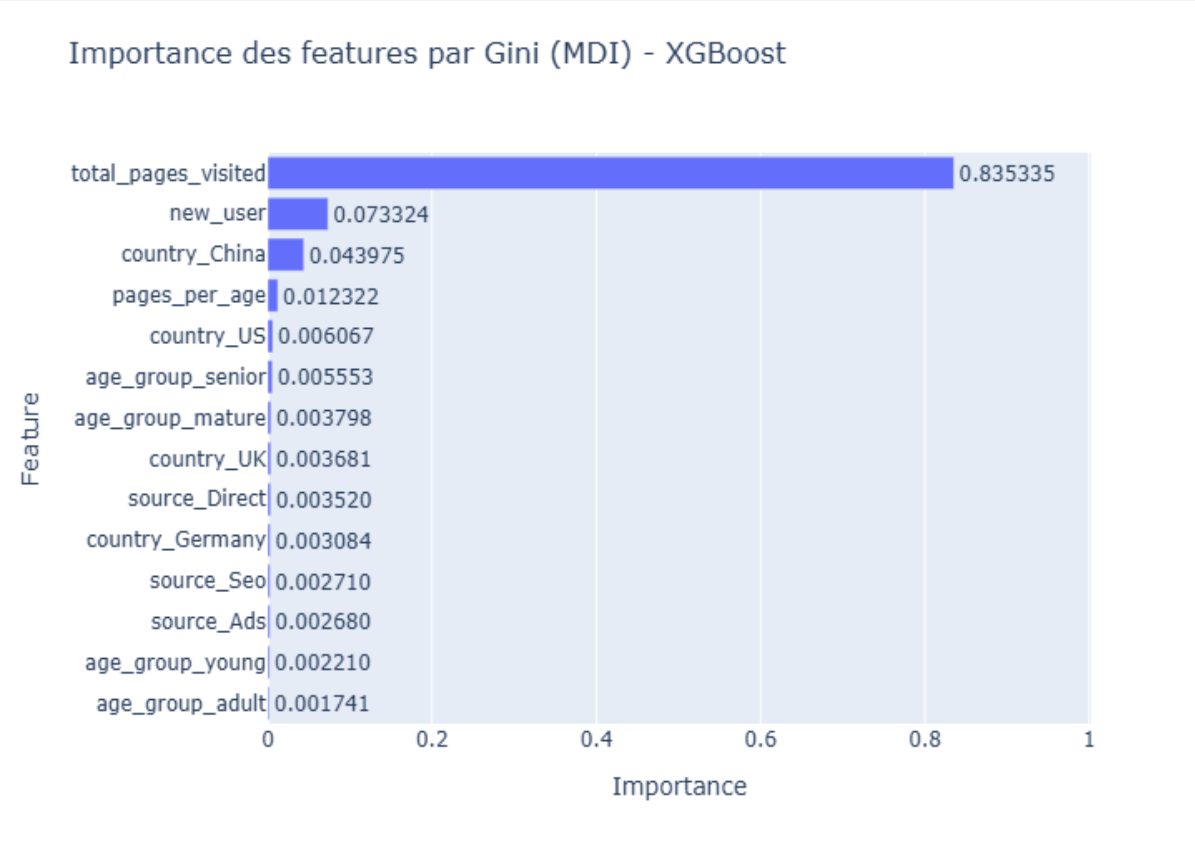
04 Résultats — Choix du modèle final

Les trois modèles sont très proches en terme de F1 score. Une légère amélioration dans le XGBoost.

RF et XGBoost ont un F1 score mieux équilibré (entre précision et recall) que la régression logistique.

Pour ce challenge, le choix se dirige vers le XGBoost qui donne le meilleur compromis entre socre F1 et équilibre precision/recall.

04 Résultats — Importance des variables (XGBoost)



Interprétation

83,5 % **total_pages_visited**

Prédicteur quasi unique. Le comportement de navigation prime sur tout le reste.

7,3% **new_user**

Utilisateurs existants convertissent 5x plus que les nouveaux.

5,7 % **country**

La Chine tire le score vers le bas (0,1% de conversion).

05 Recommandations — Leviers d'action

1

PRIORITÉ HAUTE

Augmenter le nombre de pages visitées

C'est le levier n°1. Mettre en place des liens recommandés, une sidebar d'articles récents et des aperçus de numéros précédents pour inciter les visiteurs à explorer d'avantage de contenu.

Impact potentiel : très élevé

2

PRIORITÉ HAUTE

Cibler les utilisateurs existants

Les visiteurs anciens convertissent 5x plus. Mettre en place du retargeting pour inciter les visiteurs à revenir sur le site. Un visiteur qui revient est un futur abonné.

Impact potentiel : élevé

3

PRIORITÉ MOYENNE

Cibler la tranche 18-25 ans

Les jeunes professionnels (étudiants, bootcamps data) représentent le segment qui convertit le mieux par tranche d'âge (5,1%). Orienter les campagnes vers LinkedIn et les formations data.

Impact potentiel : modéré

4

PRIORITÉ BASSE

Investiguer le cas Chine

Le taux de 0,1% en Chine semble lié à des contraintes techniques ou réglementaires.

À investiguer

Conclusion

✓ XGBoost retenu : F1 = 76,5% — meilleur compromis parmi les trois modèles.

✓ total_pages_visited : prédicteur dominant à 83,5% d'importance

✓ Levier prioritaire : augmenter l'engagement sur le site pour faire passer les visiteurs au-delà de 15 pages vues

Merci de votre attention !

Des questions?