THE NORTH FACE

Commerce électronique : dynamiser les ventes en ligne

Apprentissage automatique appliqué au catalogue produits

Samer MECHHOUD

CONTEXTE ET PROJET

L'ENTREPRISE

The North Face
Fondée en 1968 pour équiper les grimpeurs, The North Face produit des vêtements, chaussures et équipements de plein air.

D'abord spécialisée outdoor, la marque est devenue une icône de la mode dans les années 2000.

OBJECTIF MARKETING

Booster les ventes sur thenorthface.fr grâce au machine learning.

1 Système de recommandation
"Vous aimerez aussi..." sur chaque page produit

2 Extraction de thèmes
Réévaluer et restructurer les catégories du catalogue

Corpus : 500 descriptions de produits du catalogue The North Face | Source : sample-data.csv

PIPELINE TECHNIQUE

1

Données brutes

500 descriptions
HTML (CSV)

2

Prétraitement spaCy

Nettoyage HTML
Lemmatisation
Stop words

3

TF-IDF

5 000 termes
Unigrams +
Bigrams

4

DBSCAN

Distance cosinus
eps=0.72
min_samples=3

5

LSA / SVD

20 thèmes
latents

Toutes les étapes sont implémentées en Python dans le notebook Jupyter fourni.

PARTIE 1 - CLUSTERING DBSCAN

PRINCIPE

Algorithme basé sur la densité : détecte automatiquement le nombre de clusters

Distance cosinus adaptée aux données textuelles TF-IDF

Identifie les outliers (label = -1) sans les forcer dans un cluster

Paramètres

eps = 0.72 | min_samples = 3 | metric = 'cosine'

14

clusters formés

5.4%

taux d'outliers

241

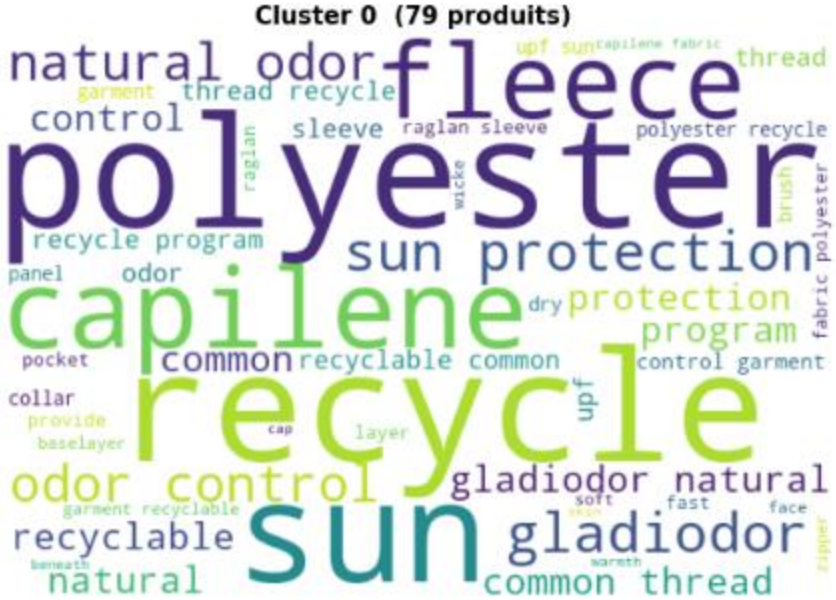
max produits / cluster

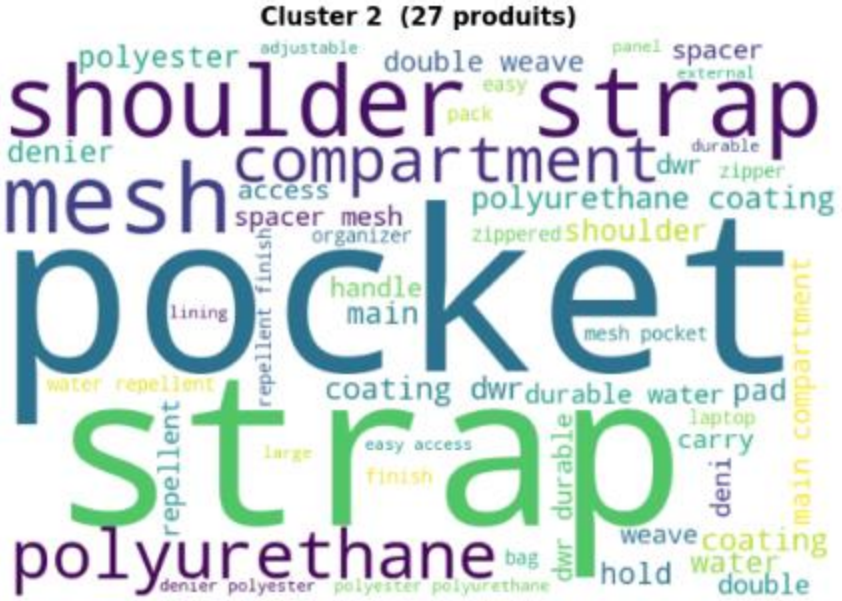
3

min produits / cluster

Les wordclouds (page suivante) confirment la cohérence sémantique de chaque cluster : sous-vêtements, vestes, pantalons, chaussures, sacs, laine mérino, etc.

WORDCLOUDS PAR CLUSTER DBSCAN





14 clusters sémantiques identifiés — chaque nuage révèle les termes les plus caractéristiques du groupe.

PARTIE 2 - SYSTÈME DE RECOMMANDATION

1

Identifier le cluster

On récupère le cluster DBSCAN du produit consulté par l'utilisateur.

2

Calculer la similarité

On calcule la similarité cosinus entre ce produit et tous ses voisins du même cluster via la matrice TF-IDF.

3

Retourner les 5 plus proches

On retourne les 5 produits par ordre décroissant de similarité cosinus.

PARTIE 3 - MODÉLISATION THÉMATIQUE LSA

Analyse Sémantique Latente (LSA) avec TruncatedSVD

Contrairement au clustering, la LSA projette chaque produit dans un espace multi-thèmes : un même produit peut être associé à plusieurs thèmes simultanément.

20

thèmes latents extraits

30.5%

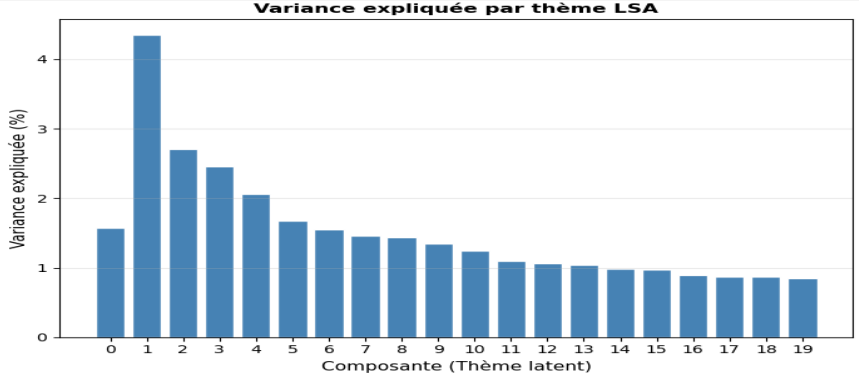
variance expliquée par 20 composantes

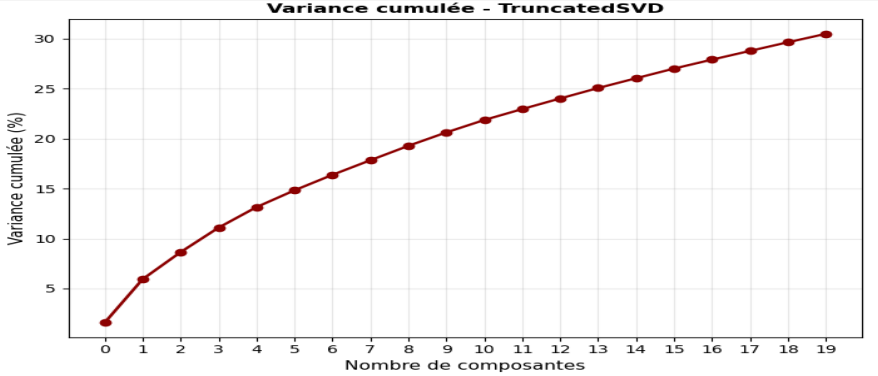
500

produits recodés

topic_encoded_df

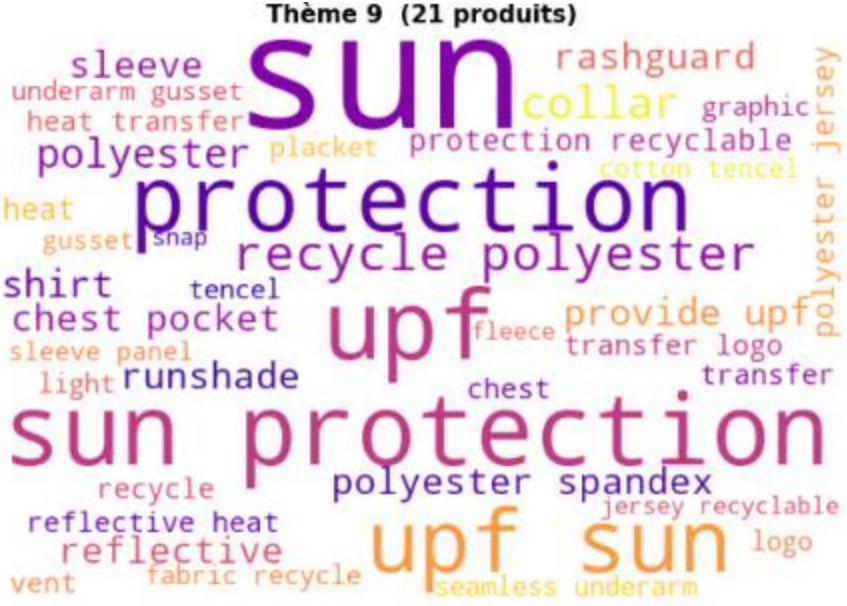
matrice document × thèmes





WORDCLOUDS PAR THÈME LSA (TruncatedSVD)





SYNTHÈSE ET CONCLUSION

01

Clustering DBSCAN

- 14 clusters sémantiques identifiés
- Seulement 5.4% d'outliers
- spaCy + TF-IDF + Distance cosinus
- Wordclouds : cohérence validée

02

Recommandation

- Tri par similarité cosinus décroissante
- 5 produits les plus pertinents
- Interface utilisateur via input()

03

Modélisation LSA

- 20 thèmes latents extraits
- Représentation multi-thèmes
- Complémentaire au clustering

Merci de votre attention !

Des questions?