Projet Getaround



Analyse des retards et optimisation du prix de location

Pipeline de Machine Learning - de l'analyse exploratoire au déploiement en production

Samer MECHHOUD

Contexte et problématique

Getaround, plateforme de location de véhicules entre particuliers, fait face à un double enjeu produit.



Enjeu 1 - Friction client

Les retours en retard entre deux locations consécutives génèrent des frictions pour le conducteur suivant : attentes, annulations, mécontentement.

Question : faut-il imposer un délai minimum entre deux locations et lequel ?



Enjeu 2 - Valorisation des véhicules

Les propriétaires ne savent pas comment valoriser leur véhicule. Un prix trop bas réduit leurs revenus, un prix trop haut décourage les locataires.

Question : peut-on prédire le prix journalier optimal à partir des caractéristiques du véhicule ?

Une analyse de données et un modèle de Machine Learning, déployés en production.

Données

Analyse des retards - Dashboard

`get_around_delay_analysis.xlsx`

21 310 locations - 8 143 véhicules
Variables : type de check-in, état, délai de restitution, écart prévu entre deux locations chaînées

Prédiction du prix - API

`get_around_pricing_project.csv`

4 843 véhicules - prix journalier
Variables : marque, kilométrage, puissance moteur, carburant, équipements (GPS, climatisation, Connect)

Analyse des retards - chiffres clés

57,5 %

des restitutions sont en retard

sur 16 345 locations analysables

+9 min

délai médian au checkout

moyenne tirée par les valeurs extrêmes

8,1 %

de locations chaînées exploitables

1729 cas où une location en suit une autre

12,6 %

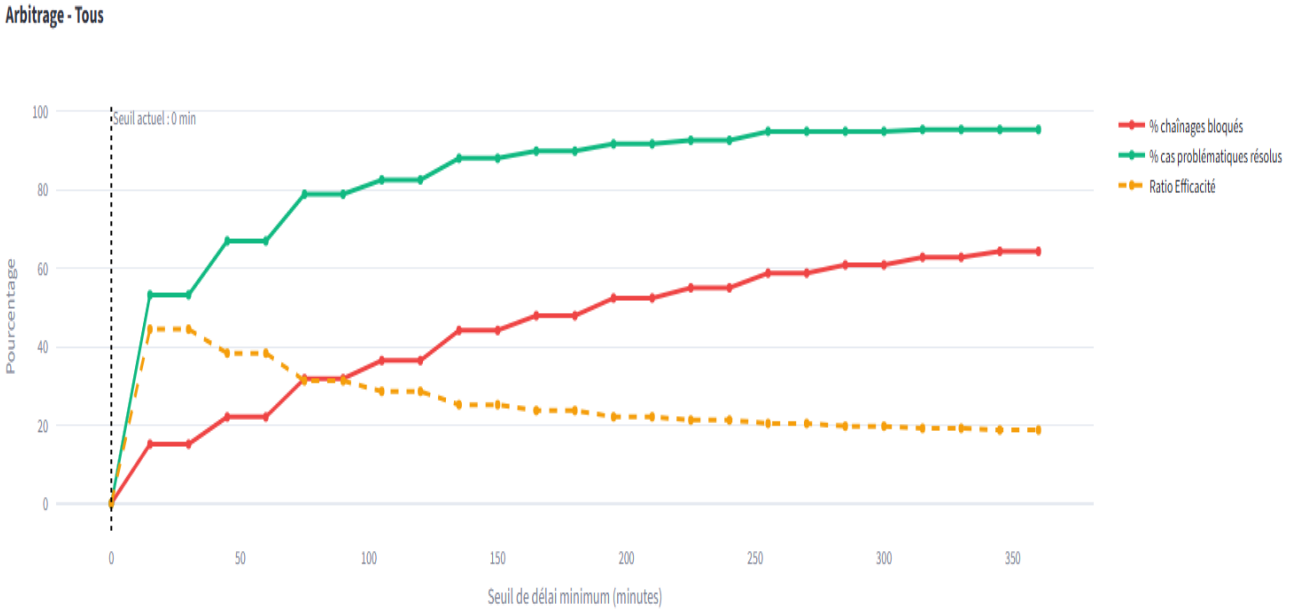
des chaînages sont problématiques

le retard précédent dépasse l'écart prévu

Le canal Connect est plus discipliné : 42,9 % de retards contre 61,4 % en Mobile.

Simulation des seuils

Pour chaque valeur de seuil, on mesure le pourcentage de cas problématiques résolus et le ratio d'éfficacité par rapport au nombre de locations chainées impactées.



Sweet Spot

90

minutes

79%

des problèmes résolus

Recommandations produit

Trois scénarios envisageables selon le niveau d'aversion au risque commercial.

Prudent

Risque commercial minimal

Seuil

60 min

Portée

Connect uniquement

Cas résolus

70 %

Équilibré

Recommandé

Seuil

90min

Portée

Ensemble du parc

Cas résolus

79%

Limite

Protection maximale

Seuil

120min

Portée

Ensemble du parc

Cas résolus

83 %

Le seuil de 90 minutes sur l'ensemble du parc offre le meilleur rapport problèmes résolus / éfficacité.

Déploiement

Code source - GitHub

Dashboard Streamlit

- Visualisations Plotly interactives
- Simulateur de seuil paramétrable
- Filtrage par périmètre (canal de check-in)

>

Conteneurisation

Docker

>

Hébergement

GCP_Cloud Run

>

Accès Public

Modélisation du prix - pipeline scikit-learn

Le pipeline assure un prétraitement reproductible et déployable.

Nettoyage

Suppression des valeurs aberrantes (kilométrage, puissance, prix)

>

Prétraitement

StandardScaler (numérique)
OneHotEncoder (catégoriel)

>

Modèle

Comparaison de 5 algorithmes
XGBoost retenu

>

Évaluation

Train / Test 80/20
MAE, RMSE, R^2

Suivi des expérimentations - MLflow Tracking server sur Hugging Face

Chaque exécution est tracée : hyperparamètres, métriques (MAE, RMSE, R^2). La comparaison entre les algorithmes devient reproductible et auditable.

Comparaison des modèles

Cing algorithmes évalués sur le même jeu de test. Métrique principale : MAE (erreur absolue moyenne en EUR).

	Modèle	MAE (EUR)	RMSE (EUR)	R^2
4	XGBoost	9.18	12.82	0.8459
3	Random Forest	9.59	13.47	0.8299
2	Gradient Boosting	9.61	13.32	0.8336
1	Ridge	11.56	15.79	0.7661
0	Régression linéaire	11.58	15.81	0.7657

Modèle retenu

XGBoost

MAE

9,18 EUR

RMSE

12,82 EUR

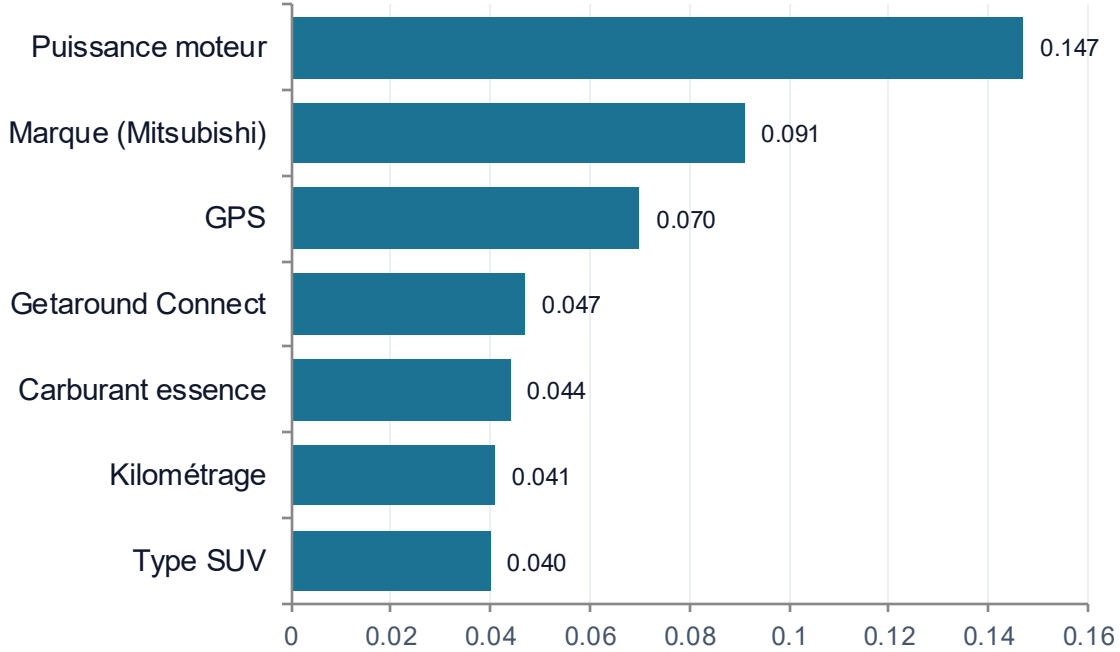
R^2

0,846

Une erreur absolue moyenne de moins de 10 EUR sur un prix qui s'étale principalement entre 40 et 250 EUR par jour.

Variables explicatives du prix

Top 7 des variables qui influencent le plus la prédiction du prix journalier (importance Gini).



La puissance moteur explique à elle seule près de 15 % de la variabilité du prix.

La marque et les équipements de confort (GPS, Connect) apportent une plus-value mesurable.

Déploiement

Code source - GitHub

FastAPI

- Endpoint /predict (POST)
- Documentation HTML sur /docs

>

Conteneurisation

Docker

>

Hébergement

GCP_Cloud Run

>

Accès Public

Démonstrations en ligne

Tableau de bord

Analyse interactive avec simulateur de seuil

https://getaround-dashboard-770512542898.europe-west9.run.app/

API de prédiction

Documentation interactive et test du modèle

https://getaround-fastapi-770512542898.europe-west9.run.app/docs

Conclusion et perspectives

Un projet de bout en bout, du jeu de données brut au service consommable par l'équipe Produit.

Livrables

- Recommandations chiffrées sur les seuils de délai entre locations
- Tableau de bord interactif pour l'équipe Produit
- Modèle XGBoost (MAE 9,18 EUR, R^2 0,846)
- API REST documentée déployée en production
- Suivi MLflow reproductible

Pistes d'amélioration

- Affiner la segmentation par profil de véhicule
- Ajouter des variables géographiques et saisonnières
- Mettre en place un monitoring du drift du modèle
- Industrialiser le réentraînement périodique

Merci de votre attention !

Des questions?